



Universidad
Rey Juan Carlos

GRADO EN INGENIERÍA EN SISTEMAS AUDIOVISUALES
Y MULTIMEDIA

Curso Académico 2022/2023

Trabajo Fin de Grado/Máster

TÍTULO DEL TRABAJO EN MAYÚSCULAS

Autor : Carmen González López

Tutor : Gregorio Robles Martínez

Trabajo Fin de Grado/Máster

Título del Trabajo con Letras Capitales para Sustantivos y Adjetivos

Autor : Carmen González López

Tutor : Gregorio Robles Martínez

La defensa del presente Proyecto Fin de Carrera se realizó el día de
de 202X, siendo calificada por el siguiente tribunal:

Presidente:

Secretario:

Vocal:

y habiendo obtenido la siguiente calificación:

Calificación:

Fuenlabrada, a de de 202X

*Dedicado a
mi familia y amigos*

Agradecimientos

Con la culminación de este proyecto llego al final de mi etapa universitaria, dejando atrás un período que guardaré en mi memoria para siempre. Empecé esta etapa mudándome a una ciudad extraña llena de extraños, a esto se le añadieron los retos que en sí supone un Grado en Ingeniería como este.

Echando la vista atrás me doy cuenta de que no sólo he crecido profesionalmente, al haberme formado como ingeniera en Sistema Audiovisuales y Multimedia, sino que también he crecido a nivel personal. Esto ha sido gracias a la experiencias y conocimientos que se adquieren en esta etapa, al estar rodeada tanto de los profesionales que me han formado durante estos años, como de los compañeros y amigos que me han apoyado en todo momento.

En primer lugar, agradecer a mi familia por creer siempre en mí, cuando ni yo misma lo hacía, en especial a mis padres, que en la distancia me han apoyado todos los días hasta el final. A ellos quiero agradecerles que me brindasen la oportunidad de formarme en un Grado Universitario, ya que soy consciente de que no todos tienen este privilegio. Agradecerles también su paciencia por escucharme tanto en los buenos como en los malos momentos y darme siempre consejo. Además, quería mencionar que ellos siempre me han inculcado que con trabajo y esfuerzo todo es posible, por lo que este logro también les pertenece.

En segundo lugar, dar las gracias a mis amigos de Madrid con los cuales he compartido el día a día y he vivido momentos increíbles. Estos han sido un pilar fundamental en esta etapa, pero sobre todo quiero hacer una mención especial a mis amigas Isabel y Carlota, con las cuales he compartido piso todos estos años y a las que considero que son mi familia de Madrid. Ellas me han enseñado a ser más positiva y que hay que disfrutar de cada instante de la vida; además, siempre me han apoyado y me han animado a salir de mi zona de confort.

Agradecer también a mis amigos de la Universidad, en particular a mis amigas Paula, Andrea, María y Karol porque sin ellas esta etapa no hubiera sido lo mismo. Todos estos años nos

hemos ayudado mutuamente, pero no sólo me quedo con los momentos vividos en la Universidad, también recordaré siempre las quedadas para evadirnos de esta.

No puedo dejar de mencionar a mis amigos de toda la vida, quienes me han brindado un apoyo incondicional durante todo este proceso. Siempre me han animado a seguir adelante y a superar los desafíos que se presentaron en el camino.

Por último, quiero expresar mi más sincero agradecimiento a mi tutor de proyecto, Gregorio Robles, por su valiosa orientación y apoyo, que me ha sido de gran ayuda durante el recorrido de este Trabajo de Fin de Grado.

A todos ellos, mi más sincero agradecimiento por el apoyo en esta etapa y por la incalculable contribución a este Trabajo de Fin de Grado.

Resumen

Ha de constar de tres o cuatro párrafos, donde se presente de manera clara y concisa de qué va el proyecto. Han de quedar respondidas las siguientes preguntas:

- ¿De qué va este proyecto? ¿Cuál es su objetivo principal?
- ¿Cómo se ha realizado? ¿Qué tecnologías están involucradas?
- ¿En qué contexto se ha realizado el proyecto? ¿Es un proyecto dentro de un marco general?

Summary

Here comes a translation of the “Resumen” into English. Please, double check it for correct grammar and spelling. As it is the translation of the “Resumen”, which is supposed to be written at the end, this as well should be filled out just before submitting.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos e hipótesis de investigación	2
1.3. ¿Qué es un UML?	4
1.4. Estructura de la memoria	5
2. Objetivos	7
2.1. Objetivo general	7
2.2. Objetivos específicos	7
2.3. Planificación temporal	8
3. Estado del arte	11
3.1. Tecnologías y herramientas	11
3.1.1. Github	11
3.1.2. MongoDB	12
3.1.3. JSON	13
3.1.4. Python	14
3.1.5. Ubuntu	15
3.1.6. WSL	15
3.1.7. LaTeX	16
3.2. Librerías	17
3.2.1. Perceval	17
3.2.2. Pymongo	18
3.2.3. Subprocess	18

3.2.4. Mongoimpot	19
3.2.5. Matplotlib	19
3.2.6. Numpy	20
4. Diseño e implementación	21
4.1. Arquitectura general	21
4.2. Procedimiento de instalación	22
4.2.1. Instalación de WSL	22
4.2.2. Instalación de Ubuntu	23
4.2.3. Instalación de Perceval	23
4.3. Recopilación de datos	25
4.4. Procesado de datos	27
4.5. Análisis de datos	31
4.5.1. Lenguaje de programación principal del repositorio	31
4.5.2. Licencia del repositorio	32
4.5.3. Tipo de propietario del repositorio	32
4.5.4. Número de fork por repositorio	33
4.5.5. Tamaño del repositorio	34
4.5.6. Número de Stars por repositorio	34
4.5.7. Número de colaboradores por repositorio	34
4.5.8. Cantidad total de commits por repositorio	36
5. Resultados	37
5.1. Descripción de los datos recopilados	37
5.2. Análisis estadístico de los datos recopilados	38
5.3. Interpretación de los resultados del análisis	39
5.4. Conclusiones de los resultados del análisis	41
6. Conclusiones	47
6.1. Consecución de objetivos	47
6.2. Aplicación de lo aprendido	47
6.3. Lecciones aprendidas	48

<i>ÍNDICE GENERAL</i>	XI
6.4. Trabajos futuros	50
Bibliografía	51

Índice de figuras

1.1. Modelo de ejemplo de un diagrama UML.	5
3.1. Estructura de un objeto JSON.	14
4.1. Descripción del proceso de extracción y filtrado de datos.	22
4.2. Características de Windows.	23
4.3. Características de Windows.	24
4.4. Estencion WSL de Visual Studio Code.	25
4.5. Descripción general de Perceval.	26
4.6. Descripción de la fase de procesamiento de datos.	28
4.7. Representación de un diagrama de caja.	35
5.1. Número de repositorios con licencia y sin licencia.	39
5.2. Número de propietarios que son usuarios y organizaciones.	40
5.3. Número de repositorios con fork y sin fork	40
5.4. Diagrama de caja del número de commits total por repositorio sin diagrama UML.	41
5.5. Diagrama de caja del número de commits total por repositorio con diagrama UML.	42
5.6. Número de repositorios por lenguaje principal de programación	42
5.7. Número de repositorios por lenguaje principal de programación	43
5.8. Número de repositorios por lenguaje principal de programación	43
5.9. Número de repositorios por lenguaje principal de programación	44
5.10. Número de repositorios por lenguaje principal de programación	44
5.11. Número de repositorios por lenguaje principal de programación	45

Capítulo 1

Introducción

En este primer capítulo, se presenta el contexto y la motivación en la que se ha desarrollado esta investigación, se exponen las preguntas que guiarán el desarrollo de este proyecto, así como información en general sobre el mismo y la estructura general que seguiremos durante el proceso de este Trabajo de Fin de Grado.

1.1. Motivación

La motivación que me ha llevado a realizar este trabajo surge de mi profesor y tutor, Gregorio Robles, quien me animó a realizar una investigación sobre los repositorios que utilizan diagramas UML y aquellos que no los utilizan en la plataforma de GitHub.

Github¹ es una plataforma que alberga una gran cantidad de información valiosa, al ser la plataforma líder en alojamiento de repositorios de código fuente. La recopilación de datos de esta plataforma nos brinda una perspectiva detallada sobre los patrones de desarrollo de software, tanto de los repositorios que contienen diagramas UML como de los que no los contienen. Esto nos permite que, al aplicar técnicas de minería de datos, podamos extraer información valiosa de grandes volúmenes de datos generados en los repositorios de GitHub y analizar estos datos para descubrir patrones que ayuden a investigadores, desarrolladores y organizaciones a tomar decisiones más informadas y mejorar la calidad del software.

Esta propuesta del profesor Robles despertó mi interés y motivación para adentrarme en el aprendizaje de las bases de datos existentes y comprender las diferencias entre ellas, así como

¹<https://github.com/>

para explorar qué datos se almacenan en los repositorios de GitHub.

Realizar este proyecto de investigación me ha brindado la oportunidad de adquirir conocimientos sobre minería de datos y de aprender a realizar un análisis detallado utilizando estas técnicas; ya que la minería de datos se ha convertido en una disciplina fundamental para extraer conocimiento útil y significativo a partir de grandes volúmenes de datos. Además, a lo largo de este trabajo, pude profundizar mi comprensión sobre el funcionamiento de los repositorios de GitHub y cómo se almacenan y organizan los datos en esta plataforma. Este me resultó de gran utilidad, a medida que exploraba y analizaba los repositorios, para identificar aquellos que utilizaban diagramas UML y compararlos con aquellos que no los utilizaban.

Durante la investigación sobre los diagramas UML me fui dando cuenta de cómo estos pueden impactar en el desarrollo de software, ya que estos se utilizan para representar visualmente la estructura y el comportamiento de sistemas de software. El uso de estos diagramas UML facilita la comunicación entre las diferentes partes involucradas en un desarrollo de software como diseñadores, desarrolladores y usuarios; además de ayudar con el mantenimiento y la comprensión del código.

Sin embargo, en la práctica, la presencia de los diagramas UML pueden variar considerablemente, ya que podemos encontrar proyectos que cuentan con varios diagramas UML que documentan de manera exhaustiva la arquitectura y diseño del sistema, mientras que otros pueden carecer de estos diagramas UML que proporcionan una documentación visual del proyecto.

La comparación entre repositorios que utilizan diagramas UML y aquellos que no lo hacen puede ayudar a los desarrolladores y equipos de proyectos a tomar decisiones con un rigor mayor sobre la utilización de diagramas UML en sus propios proyectos. Esto puede ayudar a promover el uso de UML y mejorar la calidad y eficiencia de los proyectos de software en GitHub.

1.2. Objetivos e hipótesis de investigación

El objetivo de este trabajo es analizar y comparar repositorios con y sin diagramas UML para que podamos obtener información sobre cómo estos diagramas UML pueden influir en los proyectos de los desarrolladores.

La hipótesis que planteamos en este TFG sostiene que los diagramas UML son más utili-

zados en los proyectos más grandes y complejos. Debido a esta complejidad mayor surge la necesidad de documentar y estandarizar este tipo de proyectos y de ahí que utilicen los diagramas UML.

Por otra parte, nuestra hipótesis también sostiene que los diagramas UML son más usados por organizaciones de desarrolladores que por desarrolladores individuales. Esto se debe a que las organizaciones de desarrolladores tienden a trabajar en proyectos más complejos y de mayor escala, lo que requiere una representación visual clara de la estructura y de las (interacciones del software). Los diagramas UML proporcionan esta visión general y facilitan la comunicación entre los diferentes equipos y partes interesadas involucradas en el proyecto. Además, las organizaciones de desarrolladores valoran la documentación y la estandarización en sus procesos de desarrollo de software y este tipo de diagramas son muy usados para documentar el diseño de los sistemas de software de forma que sea entendible por cualquier persona que pertenezca al equipo.

Por último, las organizaciones suelen seguir las mejores prácticas y metodologías estándar de la industria, y los diagramas UML se consideran parte integral de estas buenas prácticas.

Por todo ello, según nuestra hipótesis las organizaciones tienen una mayor propensión a adoptar y utilizar diagramas UML en comparación con los desarrolladores individuales. Sin embargo, es importante tener en cuenta que esta hipótesis puede variar dependiendo del contexto y las preferencias individuales de cada desarrollador o organización.

En cuanto a los lenguajes de programación más utilizados en este tipo de repositorios pueden variar según el proyecto y las preferencias de los desarrolladores, pero en nuestra hipótesis damos por supuesto que en la mayoría de los repositorios con diagramas UML los lenguajes de programación que predominan son algunos de los lenguajes más usados en la actualidad, como son: Java, Python o JavaScript.

Por último, mencionar que en el análisis a realizar para comprobar esta hipótesis, en sus distintas partes, incluimos otros aspectos como son: stars, forks, commits, colaboradores, licencia y el size, que nos pueden ofrecer información relevante sobre las tendencias que marcan los repositorios que tienen diagramas UML frente al resto de repositorios que no tienen diagramas UML.

1.3. ¿Qué es un UML?

A partir de lo expuesto anteriormente es necesario explicar qué es un UML y el porqué de nuestro interés por este lenguaje de modelado.

Debido a la creciente complejidad de los sistemas de software aparece la necesidad de definir modelos que faciliten la tarea de diseño y modelado de estos. Los modelos son una herramienta indispensable, puesto que facilitan la tarea de implementar sistemas que involucran gran cantidad de software al permitir comprender mejor su arquitectura, componentes e interacciones. Su uso proporciona un enfoque más eficiente y estructurado en el diseño, desarrollo y mantenimiento del software.

De esta necesidad surge el lenguaje de modelado UML² (Unified Modeling Language), que se creó para proporcionar una notación estandar y unificada con el objetivo de facilitar y estandarizar la organización de sistemas, arquitectura y diseño de software. Los modelos UML proporcionan una serie de diagramas y herramientas para el análisis, diseño e implementación de sistemas de software que ayudan a los equipos de desarrollo en la toma de decisiones sobre las metodologías que usarán durante el proceso de desarrollo de dichos sistemas de software. Estos diagramas UML³ se utilizan para documentar, especificar, visualizar y comunicar diferentes perspectivas y aspectos de un sistema de software complejo como son: su estructura, comportamiento, etc. Además, permiten analizar y diseñar un sistema de forma que se evalúe la viabilidad y calidad de estos sistemas de software.

Aunque los modelos UML principalmente se utilizan en el ámbito de desarrollo de software, también se utilizan en otros contextos como en modelar y representar los procesos de negocio, como los flujos de trabajo, las tareas, etc., lo que ayuda a visualizar y analizar procesos empresariales.

Fue creado en la década de 1990 por un grupo de expertos en software y fue respaldado por el OMG (Object Management Group) en el año 1997 como el estándar de facto para el modelado orientado a objetos de sistemas informáticos. Desde entonces, ha sido ampliamente adoptado en la industria del software y es utilizado por desarrolladores, arquitectos de software, analistas de sistemas y otros profesionales relacionados con la ingeniería de software.

En la figura 1.1 vemos un ejemplo de un diagrama UML; estos actualmente cuentan con va-

²<http://uml.org/>

³https://www.oocities.org/alvarezmiguel_uny/ads/TF.htm

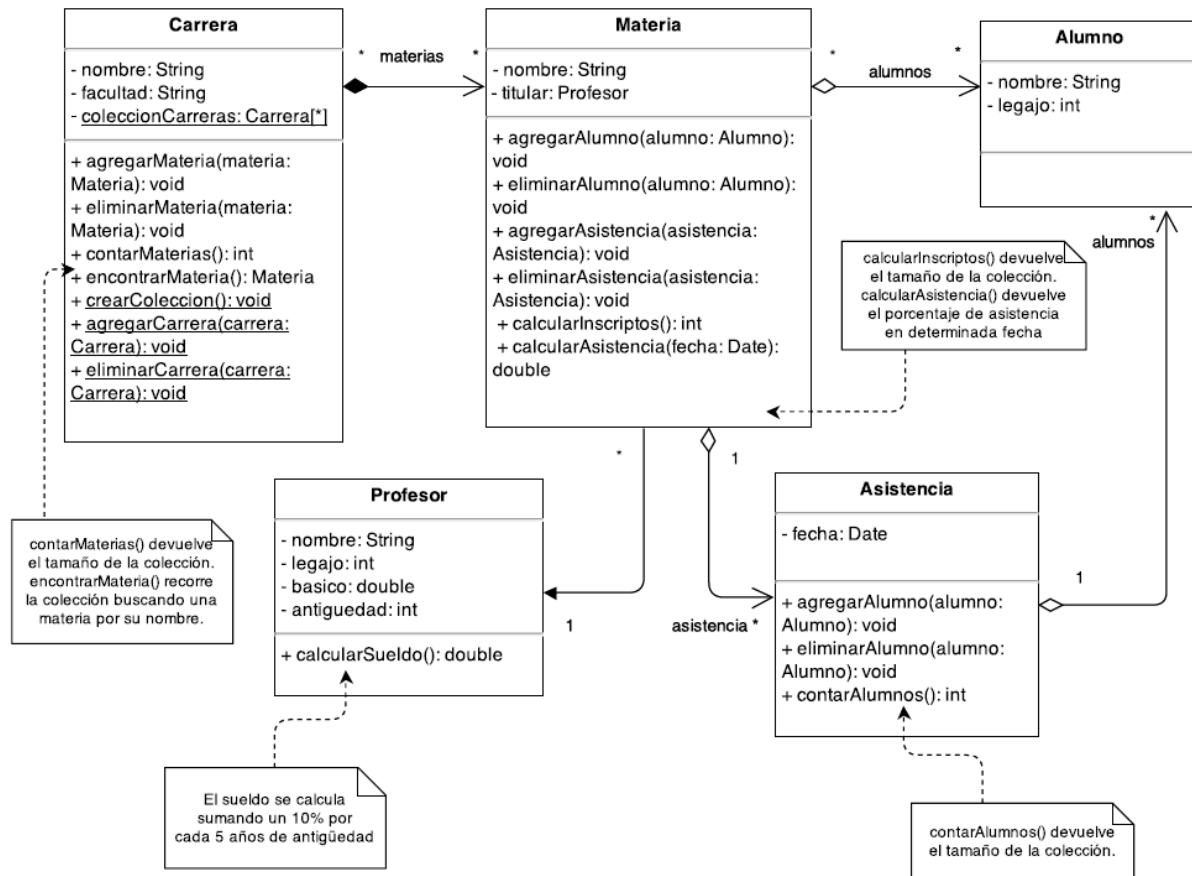


Figura 1.1: Modelo de ejemplo de un diagrama UML.

rios tipos de diagramas que se utilizan para diferentes propósitos, tienen diferentes destinatarios y se emplean en distintos contextos.

1.4. Estructura de la memoria

Describiremos la estructura de la memoria, exponiendo el contenido de cada uno de los capítulos, proporcionando así una guía organizada del trabajo de fin de grado para una mejor lectura y comprensión de este.

- **Capítulo 1: Introducción.** En esta sección se describe(en que consiste el proyecto) el contexto del proyecto, la motivación personal que ha llevado a realizarlo y la estructura de la memoria.
- **Capítulo 2: Objetivos.** En esta sección se establece el objetivo general que se pretende alcanzar con este proyecto. Así como los objetivos específicos necesarios que van a guiar

nuestro proyecto y la planificación de dichos objetivos(de todo el proyecto).

- **Capítulo 3: Estado del arte.** En esta sección se proporciona información detallada sobre el diseño, las características y los usos de cada una de las tecnologías usadas en el proyecto.
- **Capítulo 4: Diseño e implementación.** En esta sección se detallan las fases que se han llevado a cabo para realizar el análisis de estudio. También se describe la arquitectura general del proyecto, los procedimientos utilizados para la recolección y el almacenamiento de los datos y la descripción del análisis de los datos.
- **Capítulo 5: Resultados.** En esta sección se realiza una descripción detallada de los datos recopilados, de los análisis estadísticos realizados, de los resultados obtenidos en el análisis y ; además, se realiza una conclusión de dichos resultados.
- **Capítulo 6: Conclusiones.** En esta sección se presenta un resumen de los resultados obtenidos y de las conclusiones a las que se ha llegado. También se enumeran los conocimientos adquiridos durante la carrera que se han aplicado en este proyecto y los aprendidos durante la realización de este. Por último, se comentan futuros trabajos o mejoras para el estudio de los desarrolladores que utilizan archivos UML.

Capítulo 2

Objetivos

En un trabajo de fin de grado es muy importante describir el propósito final del proyecto, definir cuáles serán los aspectos a tratar, así como la planificación llevada a cabo. Todo esto ayudará a los lectores a hacer un seguimiento del proyecto. En este capítulo, se presentan los objetivos del trabajo de fin de grado y los procedimientos planteados para lograrlos.

2.1. Objetivo general

El objetivo general de este Trabajo Fin de Grado consiste en analizar repositorios de la plataforma de Github para observar las diferencias y similitudes que existen entre los repositorios que usan ficheros UML frente al resto de repositorios.

2.2. Objetivos específicos

Para lograr el objetivo general de este proyecto se han establecido los siguientes objetivos específicos:

- Estudiar y probar el funcionamiento de Perceval
- Seleccionar una serie de repositorios de GitHub y almacenarlos en una estructura JSON.
- Observar los datos amacenados en los archivos JSON obtenidos e identificar los datos que son de interés para comparar en nuestro estudio.

- Desarrollar los programas de extracción y almacenamiento de los datos escogidos en MongoDB.
- Realizar el análisis de los resultados obtenidos para determinar las similitudes y diferencias más relevantes entre los repositorios que tienen archivos UML y los que no.

2.3. Planificación temporal

A finales de abril del año pasado empecé mi proyecto de fin de grado. El desarrollo de este trabajo comenzó en mayo de 2022, cuando el profesor Gregorio Robles Martínez me sugirió la idea del proyecto que he llevado a cabo.

Durante los meses de mayo y junio empecé a documentarme sobre Lindholmen dataset¹, que es una base de datos con los repositorios que utilizan diagramas UML en GitHub. De la misma manera, obtuve la información necesaria sobre las herramientas Grimoire Perceval² y GitHub API³, las cuales se utilizan para analizar repositorios y extraer datos de estos. Después del estudio y análisis de estas herramientas, me decanté por Perceval, ya que con ella se obtienen más datos de Github.

De julio a septiembre, empecé a descargar y almacenar en MongoDB algunos de los repositorios obtenidos en Lindholmen dataset usando Perceval para ver qué datos se obtenían y cuales eran más relevantes para, posteriormente, realizar el análisis. También, inicié el desarrollo de varios programas con los que extraer los datos de interés que, previamente, había seleccionado.

Desde octubre hasta diciembre estuve desarrollando un programa que guardase todos los datos de interés extraídos en MongoDB y otro programa que analizase dichos datos almacenados en MongoDB. A la vez, fui recopilando y almacenando los datos de una serie de repositorios de desarrolladores en los que hay archivos UML y repositorios en los que no hay archivos UML. Además, almacené los commits de dichos repositorios; ya que estos contienen información de interés para el desarrollo de nuestro análisis.

Durante los meses de enero y febrero del 2023, busqué cómo introducir los archivos JSON obtenidos, tanto de los repositorios, como de los commits en MongoDB de forma automática,

¹<http://models-db.com/>

²<https://github.com/chaoss/grimoirelab-perceval>

³<https://docs.github.com/es/rest>

que hasta ese momento había hecho de manera manual. Esto supuso una mejora en el proceso de desarrollo del proyecto, ya que aceleró la introducción en MongoDB de los datos necesarios para el posterior análisis. Para ello, decidí crear un programa que ejecutase el proceso de mongoimport de cada uno de los archivos que había descargado.

(Entre marzo y abril, inicié el proceso de escritura de la memoria del proyecto...)

Capítulo 3

Estado del arte

En este apartado, se proporciona una comprensión completa y actualizada de las herramientas y librerías usadas en el Trabajo Fin de Grado. Esta exposición nos da una visión de la metodología empleada a lo largo de todo el proyecto.

3.1. Tecnologías y herramientas

3.1.1. Github

Github es una plataforma web de desarrollo colaborativo de software¹ que permite la colaboración y el almacenamiento de proyectos de código abierto o cerrado. En esta plataforma, los usuarios pueden crear y unirse a proyectos para compartir ideas, discutir posibles soluciones y colaborar entre ellos para mejorar dichos proyecto. La función principal de Github [2] es que los usuarios puedan trabajar juntos en un proyecto desde cualquier lugar y en cualquier momento, ya que, registra el desarrollo de los proyectos de forma remota en la nube y no requiere de una infraestructura de hardware específica. Github ofrece una serie de bibliotecas para ayudar a los desarrolladores en su trabajo y herramientas para la gestión de versiones del software, la gestión de problemas, la revisión de código, etc. Github integra la funcionalidad de Git que es un sistema de control de versiones distribuido. Se dice que es “distribuido” porque git tiene un historial completo de cambios, en el cual se pueden revisar los cambios realizados en el código a lo largo del tiempo. Esto permite ver las modificaciones de cada desarrollador e incluso deshacer-

¹<https://github.com/>

las si es necesario. Además permite el trabajo de varios desarrolladores en un mismo proyecto. En resumen, GitHub es una plataforma que se ha convertido en una herramienta muy popular y esencial en la comunidad de desarrollo de software, ya que permite colaborar y trabajar en equipo para crear proyectos de alta calidad.

3.1.2. MongoDB

MongoDB² es un sistema de gestión de bases de datos no relacional (NoSQL) de código abierto. MongoDB ha sido diseñado para almacenar grandes volúmenes de datos; estos datos se almacenan y recuperan en formato BSON³ (Binary JSON), en lugar de en un formato de tabla relacional. El formato BSON se inventó para solucionar algunos problemas que hacen que usar el formato de representación de objetos JSON no sea la mejor opción dentro de una base de datos. Con BSON se optimiza la velocidad, el espacio y se mejora la eficiencia; solucionando así los problemas que tiene JSON de carecer de soporte para fechas y datos binarios y de no tener una longitud fija para los objetos y las propiedades JSON. En definitiva, MongoDB es un modelo de base de datos orientado a documentos. Cuando se almacena un documento a éste se le asigna un código que facilita el manejo de los datos que contiene.

MongoDB⁴ tiene un modelo avanzado de consultas e indexación. A esto hay que añadir que cuenta con una alta disponibilidad gracias a sus sistemas en la nube y por tanto es capaz de recuperarse en caso de fallo. Esta recuperación se consigue mediante el proceso de replicación automática. Las consultas se ejecutan de la siguiente manera: MongoDB recibe por defecto al nodo (index) primario todas las lecturas y ejecuta todas las escrituras. El proceso de replicación permite tener siempre una copia exacta del nodo primario, al replicar sus datos en los nodos secundarios. En el caso de que se produzca un fallo en el sistema, el nodo primario pasaría a ser uno de los secundarios contribuyendo a la recuperación del sistema. Otro proceso con el que cuenta es la fragmentación automática (auto-sharding) y el escalado horizontal que permiten la distribución de datos en múltiples servidores de forma que si uno falla, se sustituye rápidamente por otro servidor. MongoDB también ofrece controles de seguridad integrados para todos los datos.

²<https://www.mongodb.com/>

³<https://www.mongodb.com/json-and-bson>

⁴<https://www.mongodb.com/es/nosql-explained>

Por último, MongoDB se puede ejecutar en una variedad de plataformas y sistemas operativos, y es compatible con muchos lenguajes de programación. Por ello es utilizado en una amplia variedad de aplicaciones, incluyendo aplicaciones web, aplicaciones móviles, juegos y análisis de datos, entre otros.

3.1.3. JSON

JSON⁵ (JavaScript Object Notation) es un formato ligero de intercambio de datos que se utiliza para transmitir y almacenar datos estructurados. Fue diseñado con el objetivo de que fuese un formato de texto portátil, mínimo y, originalmente, para ser utilizado con JavaScript. JSON es una colección no ordenada de pares clave-valor separados por comas y encerrados en llaves que se puede estructurar como un array o como un objeto [3]. En este proyecto usaremos la estructura JSON de objeto como podemos ver en la figura 3.1.

En el siguiente objeto JSON tenemos dos pares clave-valor entre { } y separados por una coma; en los cuales las claves tiene como valor las cadenas “string1” y “string2” {“key1”: “string1”, “key2” : “string2”}. Cada clave es una cadena de caracteres que se identifica con un valor correspondiente; estos valores pueden ser de cualquier tipo de datos: números, cadenas, booleanos, objetos y matrices. Una de las principales ventajas de JSON es que es fácil de leer y escribir para los humanos, lo que lo hace más fácil de entender y depurar en caso de problemas. Este tipo de estructuras son universales y por eso JSON es compatible con la mayoría de los lenguajes de programación y se ha convertido en un formato de datos muy popular. Por esta razón, al ser tan versátil, se utiliza en aplicaciones web y móviles para transmitir datos entre el cliente y el servidor y como formato para el almacenamiento en bases de datos NoSQL, como MongoDB, Apache Cassandra, y Redis. [7].

⁵<https://www.json.org/json-es.html>

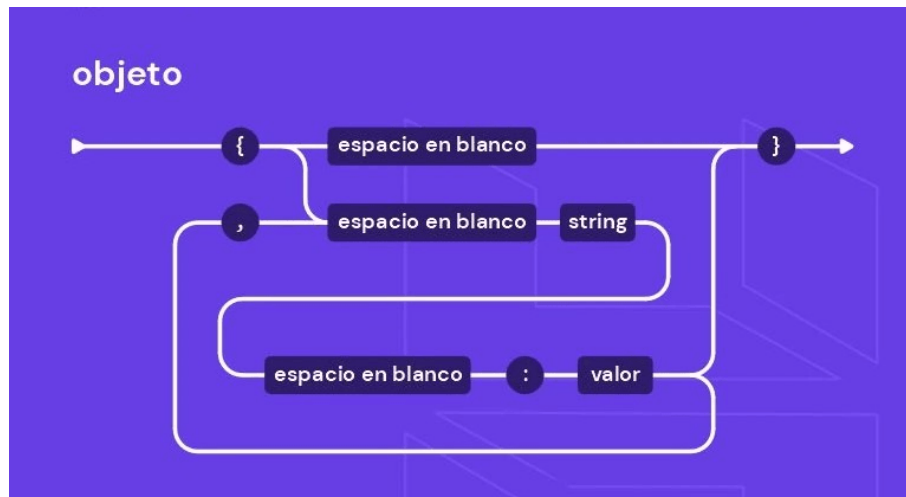


Figura 3.1: Estructura de un objeto JSON.

3.1.4. Python

Python⁶ es un lenguaje de programación de alto nivel creado por Guido van Rossum [4] y lanzado por primera vez en 1991, cuyo nombre está inspirado en el grupo de cómicos “Monty Python”.

Fue diseñado para facilitar la escritura de código y por tanto destaca por ser un lenguaje potente, sencillo, fácil de aprender y con una sintaxis clara y legible. Se considera un lenguaje multiparadigma, ya que, se apoya en diferentes estilos de programación como la programación orientada a objetos, la programación funcional y la programación imperativa. Python además cuenta con estructuras de datos para facilitar el desarrollo de software como listas, diccionarios, conjuntos y tuplas. También tiene una gran cantidad de bibliotecas y herramientas que facilitan el desarrollo de software; ya que, con ellas se obtienen soluciones en la tareas básicas de un programador.

Además, Python [8] cuenta con un intérprete propio y tiene compatibilidad con diferentes plataformas y sistemas operativos al ser un lenguaje de código abierto. Esta es una de las razones de que sea utilizado en una amplia variedad de aplicaciones, como el desarrollo web, el análisis de datos, la inteligencia artificial, el aprendizaje automático, la automatización de tareas y la creación de juegos, entre otros. Por todo esto, este lenguaje ha ganado mucha fuerza en la comunidad científica, educacional y de software libre.

⁶<https://www.python.org/>

3.1.5. Ubuntu

Ubuntu⁷ es un sistema operativo de código abierto basado en Linux diseñado con una gran cantidad de software preinstalado para satisfacer las necesidades de la mayoría de los usuarios. Fue lanzado por primera vez en 2004 y desarrollado por una empresa llamada Canonical [5], cuyo objetivo era generar un sistema fácil de instalar y utilizar, completo e innovador.

Actualmente Ubuntu [10] se ha convertido en uno de los sistemas operativos más populares en la comunidad de software libre y de código abierto. Esto se debe a que está disponible de forma gratuita para su descarga y uso de múltiples formas y, además, tiene una interfaz muy parecida a Windows lo que permite que sea intuitivo y fácil de utilizar por cualquier usuario.

Al igual que con Windows, con este sistema operativo también podemos navegar en la web, crear y modificar documentos; al ser compatible con formatos de archivos muy conocidos, y otras tareas que realizamos en nuestro día a día. Ubuntu se utiliza en una amplia variedad de sistemas, desde ordenadores hasta servidores y dispositivos móviles.

3.1.6. WSL

WSL⁸(Windows Subsystem for Linux) es un sistema diseñado por Microsoft que permite a los desarrolladores ejecutar aplicaciones y herramientas de línea de comandos de Linux directamente en Windows (por la capa de compatibilidad), sin necesidad de utilizar una máquina virtual o instalar un sistema operativo Linux en un disco duro. Este subsistema de Windows para Linux fue lanzado en 2016 y no ha dejado de evolucionar desde entonces.

WSL [6] fue creado para los desarrolladores que necesitan utilizar herramientas y aplicaciones de línea de comandos específicas de Linux, pero prefieren trabajar en el entorno de Windows. También para aquellos que necesitan trabajar en los sistemas operativos Windows y Linux simultáneamente.

La versión WSL 1 utiliza una capa de compatibilidad para la transferencia de la ejecución de código entre Windows y Linux, mientras que WSL 2 tiene una versión actualizada de su arquitectura del software con respecto a su versión anterior. Además, utiliza una máquina virtual de Linux integrada que ofrece un rendimiento alto y muy parecido al de un sistema Linux real.

⁷<https://ubuntu.com/>

⁸<https://learn.microsoft.com/es-es/windows/wsl/>

3.1.7. LaTeX

LaTeX⁹ es un sistema de composición de (textos)(documentos), el cual, está formado por un conjunto de macros TeX. Fue desarrollado por Leslie Lamport en 1984, con el fin de facilitar el uso del lenguaje de composición tipográfica de textos(documentos) TeX. TeX, también es un sistema de composición tipográfica de textos que usa funciones avanzadas de automatización para generar documentos en los cuales se usan textos y fórmulas matemáticas con un determinado estándar. Fue desarrollado por Donald E. Knuth en 1978 como herramienta para la creación de textos que contengan fórmulas matemáticas complejas.

LaTeX [9] usa las características del sistema TeX para generar documentos científicos, técnicos y académicos de alta calidad automáticamente, como artículos académicos, libros, tesis... Además, LaTeX ofrece con una variedad de paquetes, extensiones y estilos personalizados para adaptarse a las indicaciones específicas de cada usuario. Las extensiones con las que cuenta permiten insertar fácilmente imágenes, diagramas matemáticos, fórmulas matemáticas, textos de lenguajes de programación, etc.

Estos sistemas de composición de textos están disponibles en gran cantidad de plataformas; además, cuentan con editores gratuitos que facilitan la creación de documentos sin la necesidad de tener conocimientos previos de programación. LaTeX utiliza una sintaxis de comandos que permiten al usuario controlar la estructura y el formato del documento, incluyendo la disposición de los elementos, el estilo de las fuentes, las ecuaciones matemáticas, y las referencias bibliográficas.

Una vez que se domina la sintaxis y las herramientas de LaTeX, se puede crear fácilmente documentos de alta calidad de manera eficiente. Por eso LaTeX es una herramienta muy utilizada y valorada en la comunidad científica, técnica y académica se utiliza ampliamente en universidades y centros de investigación de todo el mundo por su capacidad para producir documentos de alta calidad con un aspecto profesional, incluso si se requiere un formato complejo y detallado.

⁹<https://es.overleaf.com/>

3.2. Librerías

3.2.1. Perceval

Perceval¹⁰ es uno de los componentes que contiene GrimoireLAB¹¹ que es uno de los proyectos fundadores de CHAOSS Software¹². Este proyecto fue desarrollado para ayudar a investigadores en el análisis de repositorios de software y está formado por un conjunto de herramientas gratuitas, libres y de código abierto.

GrimoireLAB es el resultado de más de 10 años de desarrollo de Bitergia, grupo de investigación de software libre de la URJC y varios colaboradores. Cada herramienta se encuentra disponible en un repositorio distinto en Github y se puede instalar fácilmente como un módulo de paquetes de Python. Dichas herramientas se crearon para la recopilación automática e incremental de información de cualquier fuente de datos, el enriquecimiento de estos con información adicional y el almacenamiento y visualización de estos datos.

GrimoireLAB cuenta con unos componentes que se pueden usar juntos o por separado para las distintas tareas que se ejecutan en un análisis de datos. Perceval, como ya hemos mencionado, es uno de estos componentes que funciona como una biblioteca/módulo y proporciona una API de Python. Está diseñado para recuperar datos relacionados con el desarrollo de software de diferentes fuentes. Estas fuentes pueden ser de gestión de problemas o tareas, de gestión o revisión de código fuente, de foros o listas de correo, de wikis, entre otros. Posteriormente, se guarda la información obtenida en una base de datos en un formato estandarizado. Los datos que obtenemos con Perceval se almacenan como diccionarios de Python o como documentos JSON como el que mostramos a continuación:

```
{
  "backend_name": "GitHub",
  "backend_version": "0.2.2",
  "data": {
    ...
  },
  "origin": "https://github.com/grimoirelab/perceval",
```

¹⁰<https://github.com/chaoss/grimoirelab-perceval>

¹¹<https://chaoss.github.io/grimoirelab/>

¹²<https://chaoss.community/>

```
"perceval_version": "0.1.0",  
"timestamp": 1476139775.852378,  
"updated_on": 1451929343.0,  
"uuid": "c403532b196ed4020cc86d001feb091c009d3d26"  
}
```

Esta herramienta es muy útil para desarrolladores, analistas de datos y cualquier persona interesada en la recuperación de información de diferentes fuentes de datos y su posterior análisis. Además, cualquier persona puede participar en este proyecto aportando soluciones para corregir errores o ideas para nuevos servicios o funciones. También, cuenta con una comunidad de desarrolladores que colaboran continuamente en el mantenimiento y la actualización de sus servicios.

3.2.2. Pymongo

Pymongo¹³ es una librería de Python que contiene varias herramientas con las que podemos interactuar fácilmente desde un archivo de Python con MongoDB, siendo este una base de datos NoSQL. Con PyMongo, se pueden realizar una variedad de tareas en MongoDB, como crear y eliminar bases de datos y colecciones, insertar, actualizar y eliminar documentos, realizar consultas y filtrar datos, entre otras posibilidades.

3.2.3. Subprocess

El módulo “subprocess”¹⁴ (subproceso), permite ejecutar un proceso que se encuentra dentro de un script de Python a la vez que se ejecuta dicho script. Esto es posible gracias a que este módulo interactúa con el sistema operativo haciendo posible ejecutar y administrar subprocesos directamente desde Python. Este módulo proporciona varias funciones y clases para interactuar con procesos externos con los cuales los desarrolladores pueden ejecutar comandos en la línea de comandos del sistema operativo y manipular la entrada y salida de estos procesos.

¹³<https://pypi.org/project/pymongo/>

¹⁴<https://docs.python.org/es/3/library/subprocess.html>

3.2.4. Mongoimport

*mongoimport*¹⁵ es una herramienta que forma parte del paquete “MongoDB Database Tools”. Esta se utiliza para importar datos de archivos en formato JSON, CSV o TSV con facilidad desde la línea de comandos a una base de datos MongoDB. Con *mongoimport*, se pueden importar grandes cantidades de datos de manera eficiente, además, se permite especificar la base de datos y la colección en la que se quieren almacenar. El comando que se ha usado para importar los archivos es el siguiente:

```
mongoimport --db nombre_base_de_datos --collection nombre_coleccion --fil
```

3.2.5. Matplotlib

Matplotlib¹⁶ es una librería de código abierto de Python que se usa para crear gráficos estadísticos, figuras interactivas, coordenadas no estructuradas, gráficos 3D y otros tipos de visualización de datos. Esta librería proporciona una amplia gama de herramientas, la mayoría se ofrecen como funciones del módulo “pyplot”, pero también integra otras librerías de Python como NumPy y Pandas, que facilita el trabajo con grandes conjuntos de datos y su visualización. Gracias a todas estas herramientas, Matplotlib permite crear gráficos de alta calidad con una sintaxis simple, por lo que se ha convertido en una opción muy popular para la generación de gráficas.

Como hemos mencionado Matplotlib utiliza el módulo Pyplot¹⁷ que fue diseñado para la generación de gráficos programáticos e interactivos. Este módulo proporciona una interfaz sencilla, semejante a la de Matlab, que además ofrece una representación de gráficas implícita. También es importante destacar que el módulo de “pyplot” tiene un conjunto de funciones sencillas con las cuales se pueden crear gráficos y personalizarlos (trazar líneas, añadir elementos, textos, etiquetas, etc.) adaptándolos a los requisitos que tenga cada usuario.

¹⁵<https://www.mongodb.com/docs/database-tools/mongoimport/>

¹⁶<https://matplotlib.org/>

¹⁷<https://matplotlib.org/stable/tutorials/introductory/pyplot.html>

3.2.6. Numpy

NumPy¹⁸ es una librería de código abierto de Python que permite realizar cálculos numéricos y operaciones matemáticas de manera eficiente. Esta librería consta de una gran conjunto de herramientas y funciones matemáticas que realizan operaciones con matrices multidimensionales y operaciones de alto nivel.

¹⁸<https://numpy.org/>

Capítulo 4

Diseño e implementación

A continuación, describiremos los métodos y herramienta utilizados para llevar a cabo el trabajo. Esto permite a los lectores entender cómo se ha desarrollado el proyecto para realizar el análisis de estudio. En este capítulo se detallan las fases del proyecto, las decisiones y justificaciones de las metodologías escogidas y el diseño e implementación para que otros puedan realizar el mismo análisis.

4.1. Arquitectura general

En la figura 4.1 mostraremos la arquitectura de este proyecto se divide en varias fases. En la primera fase se realiza la recopilación de datos de GitHub mediante la herramienta de Perceval. Con esta herramienta, nos conectamos a la API de Github para extraer los datos con información de los repositorios y los commits ej documentos JSON. En la segunda fase procesaremos estos datos antes de almacenarlos en la base de datos MongoDB, de tal forma que nos quedamos con los datos que nos interesan para el análisis que vamos a realizar y descartamos el resto de datos. En la tercera fase realizaremos un análisis estadístico de los datos recopilados.

el archivo JSON generado por Perceval se envía al backend para su almacenamiento y análisis posterior. El backend puede ser una base de datos, un sistema de análisis de datos o cualquier otro sistema que el usuario haya configurado para manejar la información recopilada.




Figura 4.1: Descripción del proceso de extracción y filtrado de datos.

4.2. Procedimiento de instalación

Para poder realizar este proyecto es necesario tener instalados WSL (Windows Subsystem for Linux) en Windows y, en dicho Subsistema de Windows, tener Ubuntu como sistema operativo, además de la librería Perceval. A continuación, procederemos a explicar los pasos a seguir para realizar las instalaciones necesarias correctamente.

4.2.1. Instalación de WSL

En primer lugar, comprobaremos que nuestro ordenador cumple con los requisitos previos a la instalación, ya que para instalar WSL se necesita tener Windows 10 versión 2004 o posterior y nuestro hardware debe ser compatible con la virtualización de Hyper-V.

Para verificar la versión de Windows, se debe abrir la Configuración y después seleccionar “Sistema” y, por último hacer clic en “Acerca de”.

Para comprobar si nuestro procesador es compatible con Hyper-V debemos ir al menú de inicio de Windows y buscar “Información del sistema”.

Si cumplimos estos requisitos, lo primero que tenemos que hacer es activar los permisos para que en Windows se pueda usar WSL. Para habilitar los permisos para usar WSL en Windows debemos seguir los siguientes pasos:

1. Ir al menú de inicio de Windows y buscar “Activar o desactivar las características de Windows”.

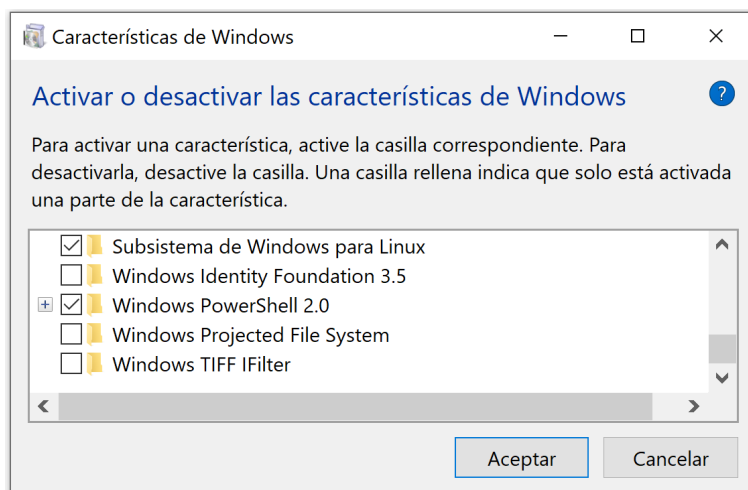


Figura 4.2: Características de Windows.

2. Marcar la casilla de verificación de “Subsistema de Windows para Linux” como podemos observar en la figura 4.2.
3. Hacer clic en “Aceptar” y esperar a que finalice el proceso.
4. Por último, reiniciar el ordenador para completar la instalación.

Una vez que nos aseguremos de cumplir estos requisitos y tener habilitado WSL en el ordenador procedemos a instalar la distribución de Linux (Ubuntu) desde la Microsoft Store para usar en WSL.

4.2.2. Instalación de Ubuntu

A continuación, descargaremos la versión de GNU/Linux que queramos usar; en nuestro caso hemos descargado la versión Ubuntu 20.04.5 LTS.

Desde la propia tienda de aplicaciones de Windows buscar “Ubuntu”, debemos seleccionar la versión deseada y hacer clic en “Obtener”, como mostramos en la figura 4.3. Cuando se ha descargado podremos comprobar que Ubuntu se ejecuta con WSL.

4.2.3. Instalación de Perceval

Antes de instalar Perceval tenemos que conectarnos al Subsistema de Windows para Linux ya que instalaremos dicha librería en este entorno. A continuación, para acceder a WSL abri-




Figura 4.3: Características de Windows.

remos Visual Studio Code e instalaremos la extensión WSL que vemos en la figura ??, que permite obtener toda la productividad de Windows mientras se trabaja con las herramientas y utilidades basadas en Linux. Con esta extensión se puede utilizar VS Code en WSL tal y como se haría desde Windows.

Una vez estemos conectados a WSL, pasamos a realizar los siguientes pasos para instalar Perceval en Ubuntu:

1. Instalar la última versión de Python y Pip, si aún no se tiene instalada en el sistema.
2. Instalar las dependencias requeridas para GrimoireLab Perceval utilizando el siguiente comando: *pip install perceval*

Para verificar que la instalación se ha completado con éxito usaremos el comando: *perceval --version* Si este comando devuelve la versión de GrimoireLab Perceval instalada, entonces la instalación se ha completado correctamente y se puede empezar a utilizar Perceval para recopilar datos de diversas fuentes de software.




Figura 4.4: Estencion WSL de Visual Studio Code.

4.3. Recopilación de datos

En esta parte del proyecto se lleva a cabo la recopilación de una lista de repositorios que utilizan archivos UML y otra en las que no se utilizan archivos UML. Para ello se recurre a Lindholmen dataset que proporciona a los investigadores listas de proyectos de código abierto que usan archivos UML y que se encuentran distribuidos en repositorios de GitHub.

A partir de este conjunto de datos se descarga el archivo “UMLFilesList” para obtener una lista de los repositorios que hacen uso de archivos UML. Este archivo proporciona los enlaces directos a los archivos UML de cada uno de los repositorios, lo que permite verificar que dichos archivos siguen formando parte de dichos repositorios. Con estos enlaces nos cercioramos de que los archivos continuen, cada uno de ellos, siendo parte de los diferentes proyectos, los cuales posteriormente procederemos a analizar.

Para obtener la lista de repositorios en los que no se usen archivos UML se procede a revisar los seguidores de los repositorios obtenidos anteriormente y se seleccionan de forma aleatoria algunos de ellos para crear dicha lista.

Una vez que se obtienen ambas listas de repositorios, se procede a descargar los datos de los mismos, así como los de los commits, empleando la herramienta Grimoire Perceval. Esta herramienta soporta más de 30 fuentes de datos de los cuales se pueden obtener datos. En la figura 4.5 vemos un esquema del procedimiento que sigue Perceval. En éste, el cliente escoge la fuente de la cual desea obtener los datos a analizar y ejecuta Perceval desde la línea de comandos con los parámetros necesarios para recopilar la información de la fuente seleccionada.

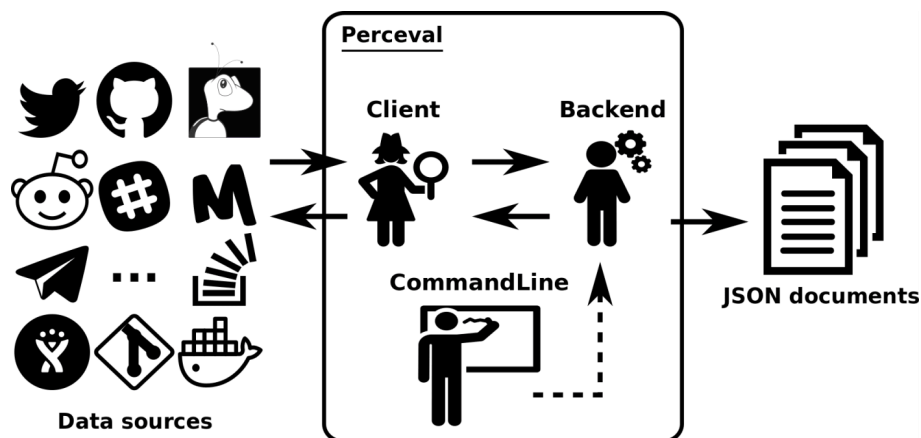


Figura 4.5: Descripción general de Perceval.

Posteriormente, Perceval procesa esta información y la almacena en documentos.

En este proyecto se eligió como fuente de datos Github. Partiendo de esta fuente de datos a Perceval se le pasaron los siguientes parámetros: el nombre del repositorio o dirección URL, el nombre y tipo de archivo con el que queremos que se guarden los documentos generados y, además, según el comando usado obtendremos los datos de los repositorios o de otras categorías como, en este caso, los commits, u otras como las issues, los pull request...

```
perceval github --category repository grimoirelab Perceval > repo.json
perceval git https://github.com/grimoirelab/perceval.git > commit.json
```

Gracias a esta herramienta, se pudo obtener información detallada de los repositorios y los commits, lo que resultó fundamental para el desarrollo de este proyecto de investigación. Estos datos se guardaron en archivos JSON, puesto que es una estructura de datos ampliamente utilizada y fácil de comprender. Para llevar a cabo esta tarea usamos una conexión WLS en la cual se instaló tanto Ubuntu como la librería de Perceval; ya que en Windows daba problemas. La instalación tanto de WLS como de Ubuntu y Perceval se han explicado en el apartado 4.2.

Después de finalizar el proceso de obtención de los datos de los repositorios se procedió a almacenarlos en la base de datos MongoDB. Para este fin, se buscó una forma de introducir los archivos JSON de forma automática. Para ello, se usó el módulo de python *subprocess* junto con *mongoimport* para desarrollar los ficheros que introducen todos los documentos JSON, obtenidos anteriormente, para crear la base de datos que vamos a estudiar. En estos ficheros se ejecuta *mongoimport* con cada uno de los archivos JSON obtenidos, tanto de los de los repositorios como de los commits con el comando que se muestra a continuación:

```
mongoimport --db project --collection Repositories --file "...\\reposito  
mongoimport --db project --collection Commits --file "...\\commit\\commit
```

en el cual;

- “Project” es el nombre de nuestra base de datos
- “Repositories” es el nombre de la colección en la que almacenaremos todos los datos extraídos de cada repositorio.
- “Commits” es el nombre de la colección en la que almacenaremos todos los datos extraídos de cada commit hecho por cada repositorio.
- “...\\repository\\repoFile.json” es la ruta en la que se encuentran todos los archivos JSON que se corresponden con los datos extraídos de los repositorios.
- “...\\commit\\commitFile.json” es la ruta en la que se han almacenado los archivos JSON con los datos de los commits generados por los repositorios

4.4. Procesado de datos

Después de almacenar todos los archivos JSON de la lista de repositorios seleccionados, empezamos a observar los datos obtenidos y se eligieron los más adecuados para analizar los tipos de desarrolladores seleccionados. Posteriormente, se inició el desarrollo de varios ficheros con los que extraer los datos de mayor interés. Al mismo tiempo, se estudió en qué tipo de base de datos se deberían guardar los archivos JSON obtenidos con Perceval. Se optó por una base de datos que no fuese relacional (NoSQL), ya que los datos no estaban relacionados entre sí y este tipo de bases de datos son muy útiles para trabajar con grandes conjuntos de datos distribuidos. Por esta razón, se decidió almacenarlos en MongoDB que es una base de datos NoSQL de código abierto.

Para almacenar estos datos se desarrollarán dos ficheros que se conectan a MongoDB y, a partir de aquí, se crea en cada uno de ellos una nueva colección con la que se introducen los datos que le pasamos. A la hora de importar los datos se decidió usar una estructura de diccionario para almacenar los datos extraídos de los repositorios y otra para almacenar los datos de los

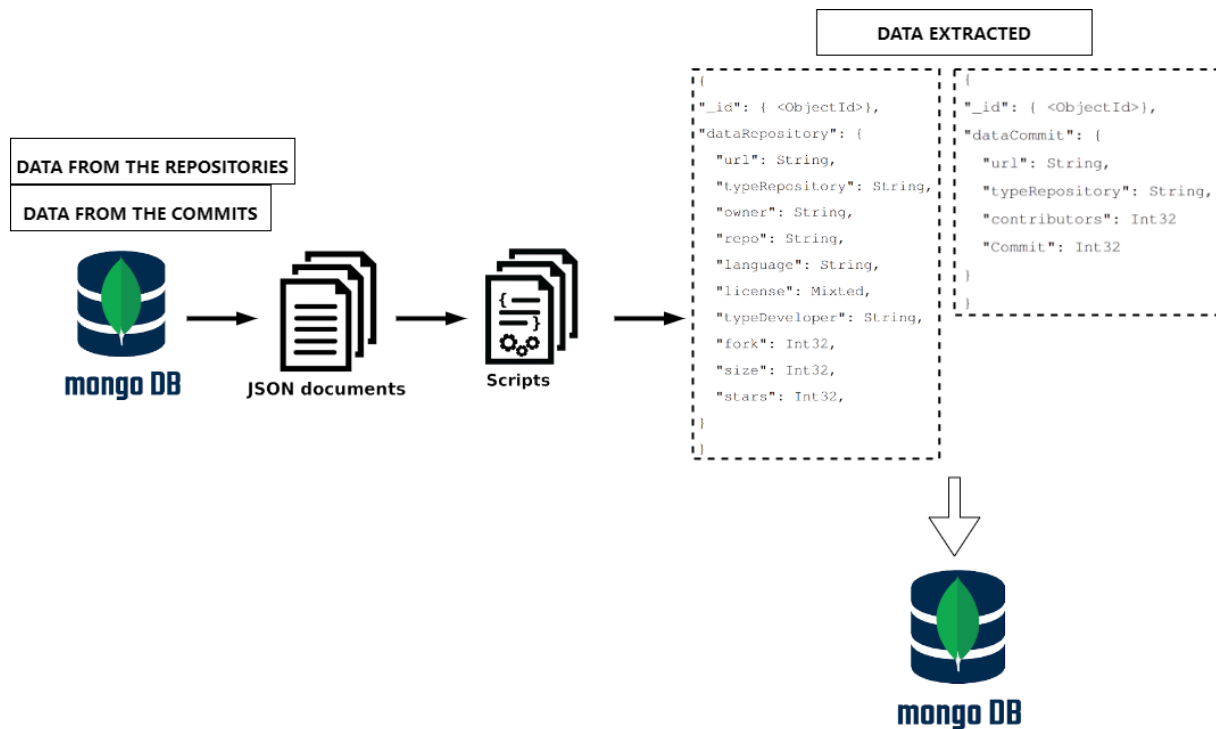


Figura 4.6: Descripción de la fase de procesamiento de datos.

commits de dichos repositorios. Las siguientes estructuras de diccionario han sido usadas para guardar la información que se usará en el posterior análisis.

Esta estructura se usó para guardar los datos obtenidos de los repositorios:

```

{
  "_id": { <ObjectId> },
  "dataRepository": {
    "url": String,
    "typeRepository": String,
    "owner": String,
    "repo": String,
    "language": String,
    "license": Mixed,
    "typeDeveloper": String,
    "fork": Int32,
    "size": Int32,
    "stars": Int32,
  }
}

```

Esta en cambio se usó para guardar los datos obtenidos de los commits:

```
{
  "_id": { <ObjectId>},
  "dataCommit": {
    "url": String,
    "typeRepository": String,
    "contributors": Int32
    "Commit": Int32
  }
}
```

A continuación, se explicaran los datos extraídos de los repositorios y los commits que se han guardado en esta estructura:

- “url”: se refiere a la ubicación del repositorio. Esta información se usa cuando un usuario quiere clonar un repositorio de Github.
- “typeRepository”: en este campo se indica si en dicho repositorio se usan archivos UML o no. Por tanto, los valores de este campo pueden ser “UML”, si en el proyecto existen archivos de este tipo, o “NOUML”, si en el proyecto no existen archivos UML.
- “owners”: en este campo se muestra el nombre del propietario del repositorio. Es decir, el usuario o la organización que creó el repositorio y que es responsable de los cambios que se producen en él. Con este campo se puede acceder a otros repositorios que sean propiedad del mismo usuario u organización. Además, también, se puede utilizar para identificar el perfil de GitHub del propietario del repositorio y ponerse en contacto con él.
- “repo”: nos muestra el nombre del repositorio, este es un identificador que se utiliza para acceder al repositorio. es decir, incluye tanto el nombre del usuario u organización, como el nombre del repositorio en sí, separados por una barra diagonal (/). Esta información nos sirve para identificar el repositorio al que pertenece la información extraída.
- “language”: nos muestra el lenguaje de programación principal utilizado en el repositorio. Los valores pueden ser, por ejemplo, “Python”, “Java”, “JavaScript”, “C++”, “Ruby”, entre otros.

- “license”: en este campo se muestra la licencia bajo la cual está disponible el código fuente del proyecto. Para que un repositorio sea verdaderamente de código abierto, tendrá que generarse una licencia. Con esta licencia cada propietario define el marco legal en el que se puede usar, distribuir o modificar el proyecto. Algunas licencias pueden ser más restrictivas que otras en cuanto a los derechos que otorgan a los usuarios y desarrolladores de software.
- “typeDeveloper”: se indica si el repositorio en cuestión pertenece a un usuario individual o a una organización. Los valores pueden ser “User”, si el propietario del repositorio es un usuario individual, o “Organization”, si el propietario del repositorio es una organización y no un usuario individual. Las organizaciones en GitHub están formadas por grupos de personas que trabajan juntas en un proyecto o en varios proyectos relacionados.
- “fork”: se indica si ese repositorio es una copia de otro repositorio existente en GitHub. Los valores de este campo pueden ser “true”, que significa que el repositorio es una bifurcación o “fork” de otro repositorio en GitHub o “false”, que significa que el repositorio no es una copia de ningún otro repositorio de Github. Los usuarios de GitHub utilizan los “fork” para crear nuevas versiones de un proyecto existente para agregar nuevas funcionalidades, corregir errores, o personalizar un proyecto original. Cada vez que se crea un “fork”, se crea una copia completa del repositorio original en el que se pueden realizar cambios sin afectar al repositorio original.
- “size”: este dato se refiere al tamaño de almacenamiento que ocupa el repositorio en kilobytes, megabytes o gigabytes. Al conocer el tamaño de un repositorio nos hacemos una idea de la magnitud del proyecto.
- “stars”: señala el número de usuarios que han marcado el repositorio como favorito, ya sea porque el repositorio le resulta interesante o útil al usuario. Esta información nos muestra qué repositorios son más relevantes o valorados por la comunidad de GitHub dependiendo de la cantidad de “stars” que tengan.
- “commit”: se muestra el número de commits que se han realizado en el repositorio. Un “commit” es una acción que se realiza para guardar los cambios realizados en los archivos de un repositorio. Todos estos “commits” se guardan en el historial del repositorio,

por tanto, esto permite a los usuarios tener la posibilidad de revisar las modificaciones realizadas y revertir cambios en caso de ser necesario. Por lo tanto, el número de commits nos puede indicar el nivel de actividad de un proyecto, así como la frecuencia de actualizaciones, mejoras y mantenimiento del mismo.

- “committers”: nos indica el número de personas que han participado en el repositorio al haber realizado commits en los cuales se ha contribuido a la mejora del proyecto del propietario del repositorio. Un gran número de colaboradores nos indica que el desarrollo del proyecto del repositorio es mayor frente a uno con pocos colaboradores.

4.5. Análisis de datos

Con el análisis de datos, que es el objetivo final del proyecto, se pretende conocer las similitudes y diferencias entre los desarrolladores que utilizan archivos UML y el resto de los desarrolladores que no utilizan este tipo de archivos.

En esta sección se describe el proceso de análisis de los datos obtenidos, a partir de Perceval, de los distintos repositorios de Github. Se comenzó por la revisión y limpieza de los datos, eliminando aquellos que decidimos no incluir, ya que no se consideraban datos relevantes para el análisis que pretendemos hacer. A partir de aquí, se procedió a la exploración de los datos, mediante el cálculo de estadísticos descriptivos, para cada una de las variables de interés. Para ello se realizó un fichero en el que se ejecuta el análisis de los datos extraídos usando Python, observando así las diferencias entre los desarrolladores que utilizan UML y el resto. A este fichero se le pasaron los 400 datos recogidos; de los cuales, la mitad son desarrolladores que usan archivos UML y la otra mitad desarrolladores que no usan archivo UML. En el fichero desarrollado se han analizado los siguientes datos de cada uno de los repositorios.

En primer lugar, se comentarán los datos que se han usado en el análisis de cada uno de los repositorios y el cálculo estadístico que se ha llevado a cabo en cada uno de ellos:

4.5.1. Lenguaje de programación principal del repositorio

Para comprobar los lenguajes de programación que predominan, según si el desarrollador utiliza archivos UML o no, se han recogido todos ellos en los documentos JSON generados.

Con esta información se realizará la media de estos datos siguiendo la siguiente fórmula para cada uno de los 10 lenguajes de programación que se han seleccionado.

$$LenguajeX = \frac{1}{200} \sum_{i=1}^{200} x_i$$

4.5.2. Licencia del repositorio

Lo primero que nos interesa conocer es el número de archivos que tienen licencia y cuáles no. Para ello se realiza un proceso de análisis estadístico de los repositorios para saber si tienen o no licencia. Para cada repositorio, se ha accedido al valor “Licencia” de los documentos JSON obtenidos con Perceval y se ha registrado la información correspondiente.

En este análisis lo primero será extraer cada uno de los documentos JSON, que hemos generado, para guardar los puntos a analizar de cada desarrollador. De cada uno de estos documentos se obtendrán los valores almacenados en el campo “Licencia”. Posteriormente, se comprobará si el objeto JSON tiene información en el valor “Licencia”; si el valor es nulo, se entiende que el repositorio no tiene licencia.

$$Licencia = \begin{cases} [licencia], & \text{si el repositorio tiene una licencia} \\ null, & \text{si el repositorio no tiene una licencia} \end{cases} \quad (4.1)$$

Después de recoger los resultados de esta función comparativa, se procede a realizar la media de los 200 repositorios con archivos UML y la media de los 200 que no tienen este tipo de archivos.

$$Licencia = \frac{1}{200} \sum_{i=1}^{200} x_i$$

4.5.3. Tipo de propietario del repositorio

Otro de los datos relevantes que nos interesa conocer es el tipo de propietario de los repositorios, si usuario único o bien un usuario que es una organización. Para ello se procede a estudiar el promedio de los tipos de propietarios de los desarrolladores UML y del resto de los desarrolladores. Los posibles tipos de propietarios que puede haber son “User”, si es un usuario único o “Organization” si se trata de una organización compuesta por varios usuarios. Esta información se muestra también en los documentos JSON obtenidos de los repositorios.

$$Propietario = \begin{cases} User, & \text{si el propietario del repositorio es un usuario} \\ Organization, & \text{si el propietario del repositorio es una organización} \end{cases} \quad (4.2)$$

Después de haber definido los propietarios de cada uno de los repositorios, se realizará la media de todos ellos para conocer si los repositorios que contienen archivos UML suelen ser propiedad de organizaciones o de usuarios únicos. A continuación se muestra la fórmula usada para realizar las medias de los repositorios cuyos propietarios son usuario o desarrolladores:

$$User = \frac{1}{200} \sum_{i=1}^{200} x_i$$

$$Organization = \frac{1}{200} \sum_{i=1}^{200} x_i$$

4.5.4. Número de fork por repositorio

Un tercer tipo de dato que nos interesa en este análisis es saber si se han hecho bifurcaciones de los repositorios. Para obtener dicha información se usará la función, que indicamos más adelante, que nos permitirá comprobar si en los repositorios, que se han seleccionado, se han realizado fork o no. En los datos extraídos con Perceval de los repositorios se encuentra el campo “forks” con el cual se comprueba el número de bifurcaciones (“forks”) del repositorio. En caso de que el valor de este campo sea distinto de “0”, se habrán realizado “forks”; en caso contrario, no se habrán realizado “forks” en el repositorio.

Una vez que se han definido el número de “forks” de cada repositorio, se procederá a realizar la media de todos ellos para conocer el número de “forks” medio que se suele realizar en los repositorios con UML con respecto al resto de repositorios si diagramas UML. A continuación se muestra la fórmula usada para realizar la media del número de “forks” por repositorio:

$$Fork = \frac{1}{200} \sum_{i=1}^{200} x_i$$

4.5.5. Tamaño del repositorio

Este dato se corresponde con un tamaño aproximado de un repositorios en kilobytes; usando los clasificadores mayor que, menor que clasificaremos los repositorios según su tamaño aproximado:

4.5.6. Número de Stars por repositorio

El último dato que nos interesa de los extraídos en los repositorios es el del número de “stars” por repositorio. Este número nos dice la cantidad de usuarios que han marcado dicho repositorio como favorito y por tanto nos indica la popularidad de éste dentro de la comunidad. Para obtener el número de “stars” por repositorio buscaremos el campo “stargazers count” en los datos extraídos mediante Perceval. Después de realizar una recopilación con el número se “stars” por repositorio, se realizará la media entre todos los repositorios.

$$Stars = \frac{1}{200} \sum_{i=1}^{200} x_i$$

A continuación, se comentarán los datos utilizados en el análisis que han sido obtenidos desde los commits de los repositorios y los cálculos empleados en cada caso. Para analizar los datos obtenidos de los commits calcularemos los diagramas de caja de cada una de las distribuciones de datos obtenidos.

Un diagrama de caja es una representación gráfica que muestra la distribución de un conjunto de datos. En esta representación gráfica se pueden observar de manera visual varios valores estadísticos como podemos observar en la figura 4.7. Estos valores estadísticos que podemos encontrar en un diagrama de caja son: el rango intercuartílico (RIC) que se representa como una caja rectangular y es el rango que abarca el 50 % de los datos, la línea dentro de la caja representa la mediana, los bigotes que se encuentran en los extremos de la caja y los cuales representan los valores máximo y mínimo y, por último, los valores atípicos que se representan mediante puntos colocados por encima del bigote superior o por debajo del bigote inferior.

4.5.7. Número de colaboradores por repositorio

En este caso se va a realizar un diagrama de caja con el conjunto de datos sobre el número de personas que hacen commits por repositorio. El número de personas que han realizado commits

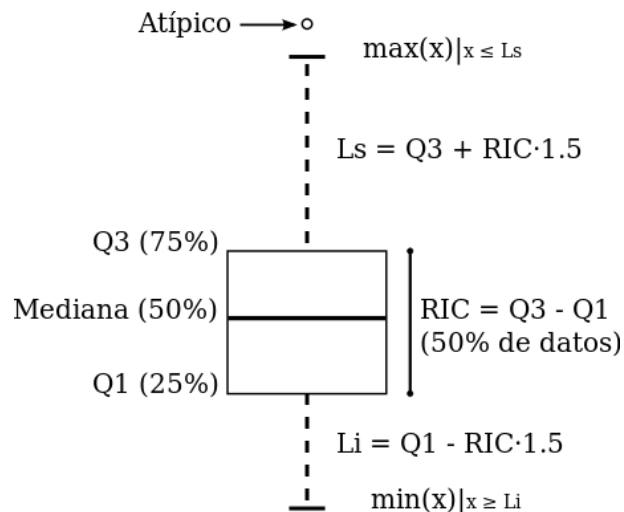


Figura 4.7: Representación de un diagrama de caja.

en un repositorio nos indica si hay una colaboración grande o pequeña en el desarrollo del repositorio. Este dato a analizar se obtiene de los documentos JSON extraídos de los commits realizados en cada repositorio, por lo que se realizarán dos diagramas de caja. Uno de ellos nos dará una representación visual de la distribución del conjunto del número de colaboradores en repositorios con diagramas UML y el otro nos dará una representación visual de la distribución del conjunto del número de colaboradores en repositorios sin54 diagramas UML. Con este tipo de representación se puede observar varios valores estadísticos del conjunto de datos como se ha mencionado anteriormente.

Nos fijaremos en la variabilidad de los datos, para ello, se observarán los cuartiles que dividen un conjunto de datos ordenados en cuatro partes iguales. El valor del primer cuartil (Q1) divide el conjunto de los datos en el 25 % que contienen los datos más bajos del conjunto, la mediana que divide el conjunto de datos en el 50 % y el tercer cuartil (Q3) que representa el 25 % de los datos con valores más altos. Además de observar estos datos, examinaremos el rango en el que se concentran los datos y que se corresponde con el rango intercuartílico (RIC) y se calcula mediante la diferencia entre el tercer cuartil y el primer cuartil ($RIC = Q3 - Q1$).

Por último, nos fijaremos en los valores atípicos en el conjunto de datos que indican valores inusuales. Estos valores se calculan siguiendo las siguientes fórmulas que nos dan los valores atípico inferiores al primer cuartil ($Q1 - RIC \cdot 1.5$) o los valores superiores al tercer cuartil ($Q3 + RIC \cdot 1.5$).

4.5.8. Cantidad total de commits por repositorio

Otro dato a analizar es el número total de commits que se han realizado en cada uno de los repositorios. Este dato representa la cantidad de cambios o actualizaciones que se han realizado en el código del proyecto. Lo que nos puede dar una idea de si se ha dedicado una gran cantidad de tiempo en un proyecto o no y, por tanto, esto nos dice si el proyecto en sí es grande o no.

Para examinar el conjunto de datos del número de commits que se realizan en los repositorios que usan archivos UML y los que no los usan, se usará la representación de los diagramas de caja como se ha hecho en el caso anterior. Con esta representación usaremos el conjunto de datos relacionados con el número total de commits de cada repositorio que se encuentran almacenados en los documentos JSON de la base de datos de MongoDB. Estos documentos JSON los analizaremos separando los repositorios con UML del resto. Por tanto, se realizarán dos diagramas de caja de 200 datos cada una de ellas, para comparar la distribución del número de commits que se realizado en los repositorios con diagramas UML y la distribución del número de commits que se han realizado en repositorios sin diagramas UML.

Capítulo 5

Resultados

(Si es una herramienta de análisis lo que has realizado, aquí puedes poner ejemplos de haberla utilizado para que se vea su utilidad.)

En este capítulo se presentan los resultados obtenidos a partir del análisis de los datos recopilados de 200 repositorios de GitHub con archivos UML y 200 repositorios sin dichos archivos. Recordemos que el objetivo de este análisis es comparar estos tipos de repositorios para ver las similitudes y diferencias que existen entre ellos. Para ello se ha realizado una recolección de datos y un análisis estadístico para establecer patrones en los repositorios con archivos UML y en en lo que no hay archivos UML.

5.1. Descripción de los datos recopilados

Los datos recopilados para el análisis de este proyecto se obtuvieron de una selección de repositorios públicos almacenados en GitHub. Estos repositorios pueden contener archivos de código, documentación y otros tipos de archivos como los “.uml”. Este último tipo de archivos será el que divida los datos obtenidos para el análisis de nuestro estudio en los repositorios que lo contengan y en los que no.

Para la selección de los 400 repositorios que se han analizado en este proyecto, se han escogido 200 repositorios con archivos “.uml”, los cuales han sido obtenidos de la base de datos Lindholmen dataset¹, que contiene una lista con los repositorios que utilizan diagramas UML en GitHub.

¹<http://models-db.com/>

En cuanto a los repositorios que no contienen archivos “.uml”, estos se han recopilado manualmente de los usuarios que siguen o son colaboradores de los usuarios que aparecen en la lista de los repositorios con archivos “.uml”.

Para reunir los datos que se usarán en el análisis del proyecto, se ha recurrido a la herramienta de Perceval, con la cual se han obtenido 400 archivos en formato JSON con todos los datos de cada repositorio de GitHub y otros 400 archivos JSON con los commits generados en estos repositorios. Estos archivos JSON contienen datos estructurados de toda la información de los repositorios a analizar, lo que nos permitirá organizar y almacenar los datos de interés de cada uno de estos archivos fácilmente.

Como se ha mencionado anteriormente, el conjunto de los 400 archivos JSON, tanto de los repositorios como de los commits, se ha dividido en aquellos repositorios que usan “.uml” y aquellos que no. Con esta división de los datos contenidos en los archivos JSON, se analizarán mejor las similitudes y diferencias entre los diferentes usuarios de estos repositorios.

De las características que se pueden observar en cada uno de los archivos JSON, obtenidos tanto de los repositorios como de los commits realizados en estos, se han decidido estudiar las siguientes: la licencia (nos dice si el repositorio garantiza derechos y responsabilidades), el tipo de propietario (nos dice si el propietario del repositorio es un usuario único o una entidad que representa un grupo de personas), la existencia de forks (nos dice si el repositorio permite a colaboradores trabajar directamente en el repositorio o trabajar en una copia independiente de este), el lenguaje de programación principal (nos dice el lenguaje principal que se emplea en el repositorio), la cantidad total o frecuencia de los commits (refleja el nivel de actividad de un proyecto). Para extraer dichas características de los archivos JSON, se ha realizado un procesamiento de los datos que se encuentran en estos archivos. Con el objetivo de obtener los datos de estas características se han desarrollado varios ficheros de Python con los cuales se sacan los datos que se encuentran en diferentes campos de los archivos JSON.

5.2. Análisis estadístico de los datos recopilados

Después de recopilar y preprocesar los datos seleccionados se realiza un análisis estadístico de estos con el cuál se podrán observar las similitudes y diferencias de los repositorios que se han seleccionado en este estudio.

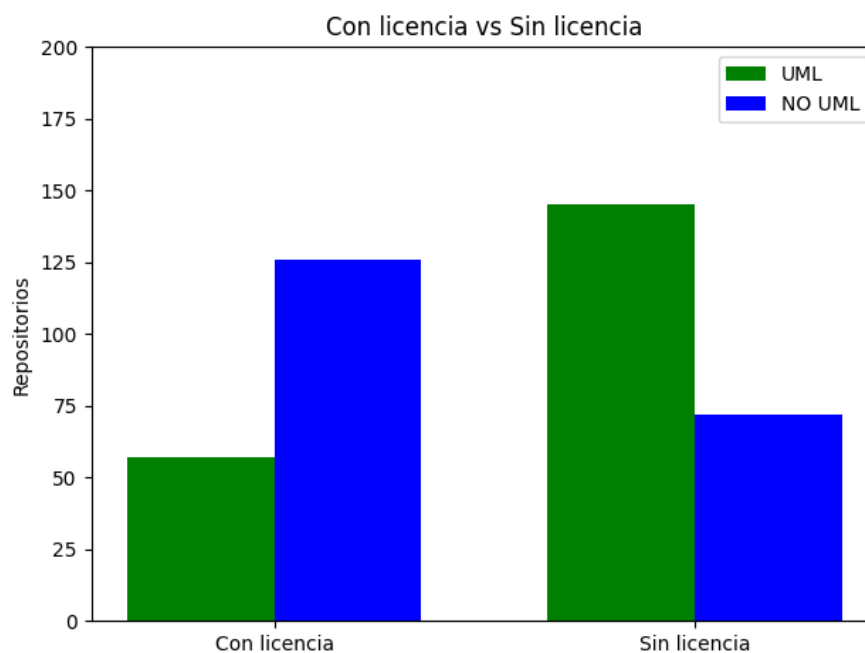


Figura 5.1: Número de repositorios con licencia y sin licencia.

5.3. Interpretación de los resultados del análisis

En la figura 5.4 se observa el diagrama de caja que representa la distribución del conjunto de número de commits de los repositorios que no tienen diagramas UML.

La línea roja en la caja muestra el valor de la mediana, que se encuentra próxima al primer cuartil, el cual se corresponde con los valores más bajos del conjunto de valores. En otras palabras, hay una concentración de valores más bajos en el conjunto de datos. Esto es que en la mayoría de los repositorios se realizan pocos commits y que solo en unos pocos repositorios se han realizado un gran número de commits.

La longitud de la caja, conocida como rango intercuartílico (RIC), es pequeña y se encuentra entre 0 y 100 commits, lo que indica que el conjunto del número de commits por repositorio está concentrado en un rango estrecho y hay poca variabilidad. Sin embargo, el bigote superior se extiende hacia valores más altos, indicando que una pequeña cantidad del conjunto del número de commits realizados están más alejados del rango intercuartílico sobre los 2000 commits.

También observamos la presencia de muchos valores atípicos, representados como puntos individuales por encima del bigote superior, llegando hasta 7500 commits. Estos valores están significativamente alejados de la mayoría de los datos y podrían ser el resultado de un cierto




Figura 5.2: Número de propietarios que son usuarios y organizaciones.




Figura 5.3: Número de repositorios con fork y sin fork




Figura 5.4: Diagrama de caja del número de commits total por repositorio sin diagrama UML.

número de repositorios en los cuales se han realizado una gran cantidad de commits que no se corresponden (con el rango típico).

En la figura 5.5 se observa el diagrama de caja que representa la distribución del conjunto de número de commits de los repositorios que tienen diagramas UML.

Al comparar este diagrama de caja con el de la figura 5.4, notamos que la mediana tiene un valor menor en este caso, lo que podría indicar que se realizan menos commits de promedio en los repositorios con diagramas UML. Además, el rango intercuartil del número de commits es mayor en el conjunto de los repositorios con diagramas UML que en el conjunto de los repositorios sin diagramas UML. Sin embargo, ambos conjuntos de datos muestran una gran cantidad de valores atípicos.

5.4. Conclusiones de los resultados del análisis

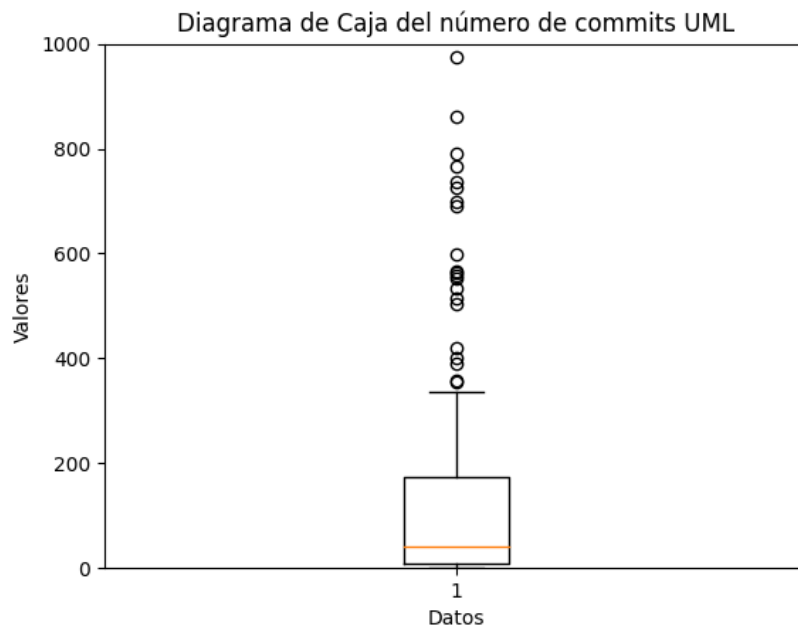


Figura 5.5: Diagrama de caja del número de commits total por repositorio con diagrama UML.




Figura 5.6: Número de repositorios por lenguaje principal de programación




Figura 5.7: Número de repositorios por lenguaje principal de programación

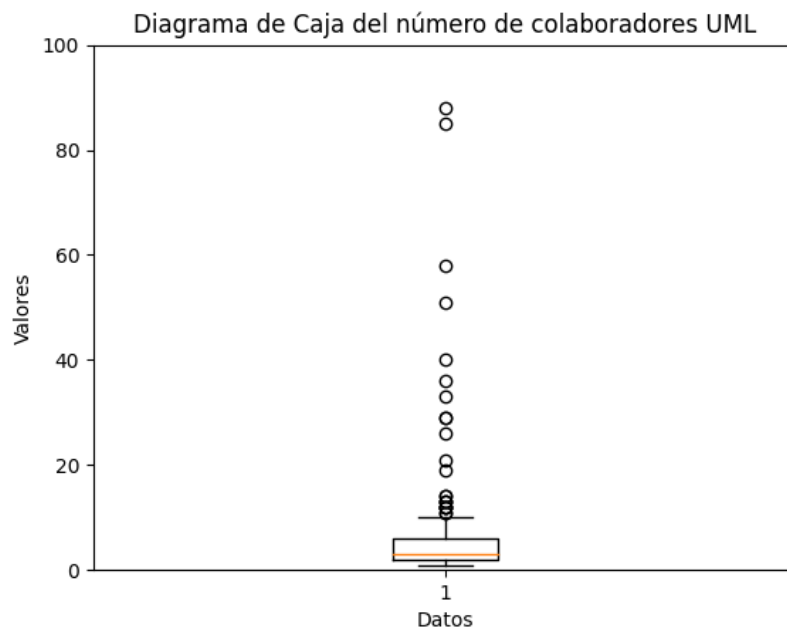


Figura 5.8: Número de repositorios por lenguaje principal de programación

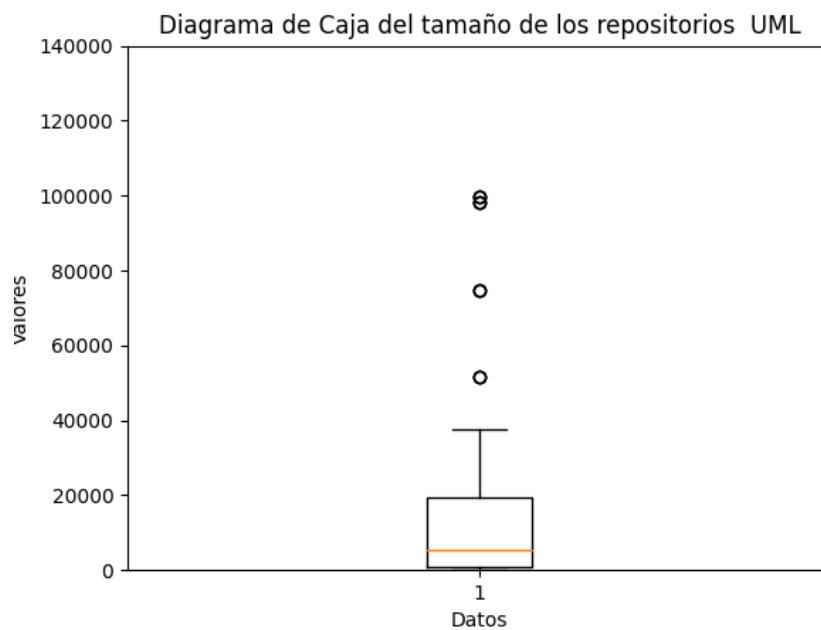


Figura 5.9: Número de repositorios por lenguaje principal de programación




Figura 5.10: Número de repositorios por lenguaje principal de programación




Figura 5.11: Número de repositorios por lenguaje principal de programación

Capítulo 6

Conclusiones

Por último, presentamos las conclusiones obtenidas tras realizar este Trabajo de Fin de Grado, en el cual se ha realizado un exhaustivo análisis de 400 repositorios almacenados en la API de Github para obtener que patrones suelen tener los repositorios que poseen modelos UML y cuales los repositorios que no tienen este tipo de modelos. (Terminar)

6.1. Consecución de objetivos

Esta sección es la sección espejo de las dos primeras del capítulo de objetivos, donde se planteaba el objetivo general y se elaboraban los específicos.

Es aquí donde hay que debatir qué se ha conseguido y qué no. Cuando algo no se ha conseguido, se ha de justificar, en términos de qué problemas se han encontrado y qué medidas se han tomado para mitigar esos problemas.

Y si has llegado hasta aquí, siempre es bueno pasarle el corrector ortográfico, que las erratas quedan fatal en la memoria final. Para eso, en Linux tenemos `aspell`, que se ejecuta de la siguiente manera desde la línea de *shell*:

```
aspell --lang=es_ES -c memoria.tex
```

6.2. Aplicación de lo aprendido

La aplicación de los conocimientos y habilidades adquiridos en mi formación académica en el Grado en Ingeniería en Sistemas Audiovisuales y Multimedia ha sido esencial para la

elaboración de este Trabajo de Fin de Grado. A continuación, se mencionan los aprendizajes que me permitieron realizar la extracción, tratamiento y clasificación de datos para obtener como resultado el análisis de este proyecto.

1. Informática I: Me sirvió fundamentalmente par adquirir las bases de programación.
2. Informática II: Aparte de reforzar las bases de programación adquiridas, obtuve una formación en otras herramientas comúnmente usadas para programar y, además, mejoré la estructuración de código y lógica necesarias en programación.
3. Protocolos para la Transmisión de Audio y Vídeo de Internet: En esta materia aprendí los conocimientos del lenguaje de programación Python además de cómo se estructura y para qué se usa la estructura de datos JSON.
4. Estadística para Sistema Audiovisuales: La adquisición de conceptos básicos de probabilidad y estadística me ha sido de ayuda en el proceso de análisis de datos de este proyecto.

6.3. Lecciones aprendidas

Durante la realización de este Trabajo de Fin de Grado, he adquirido diversos conocimientos sobre las herramientas usadas para realizar un análisis de datos. A continuación, se presentan algunos de los aprendizajes más significativos que he adquirido:

1. Al inicio de este proyecto lo primero que aprendí fue cómo funciona la herramienta de Perceval. Gracias a ella he podido obtener los datos necesarios para realizar el análisis de este proyecto, que era el objetivo final del mismo.
2. Este proyecto, además, me ha servido para entender mejor los tipos de repositorios que se encuentran en GitHub; ya que, analizando las características de estos repositorios se puede sacar mucha información de sus propietarios para ver las características que los definen, tales como si usan licencia, si son usuarios únicos o forman parte de una organización, etc.
3. He ampliado mis conocimientos sobre la estructura JSON. Esto me ha servido para comprender porque es comúnmente utilizada para el tratamiento e intercambio de datos, la

razón no es otra que su sintaxis sencilla, su formato ligero y su flexibilidad en la estructura de datos. Además, como he trabajado con archivos JSON durante la realización del proyecto, he mejorado la forma en la que tratar dichos archivos a la hora de extraer y guardar datos en dicha estructura.

4. También, he mejorado mis conocimientos de Python al emplear este lenguaje de programación en el desarrollo de los ficheros que se han usado para el tratamiento de los datos de los archivos JSON obtenidos con Perceval.
5. Utilizar MongoDB ha sido otro de los aprendizajes durante este proyecto; puesto que, no tenía apenas conocimientos de bases de datos y nunca las había utilizado. Asimismo, en este proyecto, he aprendido a usar MongoDB con Python empleando el módulo “pymongo” con el que te puedes conectar a MongoDB y trabajar con las bases de datos.
6. Aprender a usar el módulo “subprocess” ha sido muy útil; puesto que con este módulo se ha creado un fichero, que introduce todos los documentos JSON en MongoDB, de modo automático al ejecutar dicho fichero.
7. Realizar este proyecto con LaTeX ha sido otra de las lecciones que he adquirido. El aprendizaje de Latex no ha sido muy costoso y gracias a él he podido tener la memoria del Trabajo de Fin de Grado bien estructurada y organizada.

Entre las lecciones aprendidas destacaría también la adquisición o mejora de algunas destrezas necesarias para elaborar un proyecto de estas características:

1. La primera es que este proyecto me ha servido para saber determinar y acotar el objeto de investigación de un proyecto como éste y los pasos a seguir en su desarrollo.
2. La planificación y la capacidad para establecer plazos realistas sobre las diferentes etapas del proyecto ha sido otra destreza que he mejorado durante la realización de este Trabajo de Fin de Grado.
3. Otra de las destrezas que he desarrollado es a saber elegir y seleccionar qué información, entre la gran cantidad de información que existe, es relevante y cual no, puesto que no aporta nada significativo al objeto de investigación.

4. También he adquirido la aptitud para resolver y analizar los problemas que pueden surgir en un proyecto de este tipo y buscar posibles soluciones y alternativas.
5. Y, por último, el esfuerzo de síntesis a la hora de redactar el proyecto y que este resulte claro para aquellos que lo lean y quieran realizar o ampliar dicho estudio.

6.4. Trabajos futuros

Ningún proyecto ni software se termina, así que aquí vienen ideas y funcionalidades que estaría bien tener implementadas en el futuro.

Es un apartado que sirve para dar ideas de cara a futuros TFGs/TFMs.

Bibliografía

- [1] Unified modeling language (uml), 2009.
- [2] J. Astigarraga and V. Cruz-Alonso. ¿ se puede entender cómo funcionan git y github! *Ecosistemas*, 31(1):2332–2332, 2022.
- [3] T. Bray. The javascript object notation (json) data interchange format. Technical report, 2014.
- [4] I. Challenger-Pérez, Y. Díaz-Ricardo, and R. A. Becerra-García. El lenguaje de programación python. *Ciencias Holguín*, 20(2):1–13, 2014.
- [5] P. Martínez Juliá. Software libre, linux y ubuntu. *Eubacteria*, n° 17 (2006), 2006.
- [6] S. Medri. Forensic analysis of windows subsystem for linux on windows 11.
- [7] J. A. Mora-Castillo. Serialización/deserialización de objetos y transmisión de datos con json: una revisión de la literatura. *Revista Tecnología en Marcha*, 29(1):118–125, 2016.
- [8] J. R. M. Ríos, N. M. L. Mora, M. P. Z. Ordóñez, and E. L. L. Sojos. Evaluación de los frameworks en el desarrollo de aplicaciones web con python. *Revista latinoamericana de Ingeniería de Software*, 4(4):201–207, 2016.
- [9] K. E. Rodríguez and J. A. Delgado. Edición de textos científicos en latex. 2014.
- [10] I. H. P. Tavera et al. Software libre (ubuntu). *Vida Científica Boletín Científico de la Escuela Preparatoria*, (4):1, 2013.